

LAPORAN STATISTIK (STI 2025) AUDIT REPOSITORY PANDAS

Target Repositori : pandas-dev/pandas (GitHub)

Tautan Repositori Proyek : <https://github.com/Fahmi661/stat-audit-pandas-sti-2025>

Tautan Video Presentasi Proyek :

<https://drive.google.com/drive/folders/1VZo67BZrGPNjWE6OPQQew4dFO3cZen13?usp=sharing>

Program Studi : Sistem dan Teknologi Informasi (STI), Angkatan 2025

Fakultas / Kampus : Fakultas Teknik, Universitas Negeri Jakarta

ANGGOTA KELOMPOK & PERAN:

1. Zaki Musthafa (NIM: 1519625057) - Member B: Estimation Analyst
2. Ahmad Fahmi Fadillah (NIM: 1519625001) - Member A: Data Engineer
3. Felisgi Mashinta (NIM: 1519625038) - Member C: Inference Analyst
4. Muhammad Hikmal Mutaqin (NIM: 1519625005) - Member D: Hypothesis Analyst
5. Faadhel Mubarakk (NIM: 1519625012) - Member E: Computation Analyst

1. Ringkasan Eksekutif

Repositori **pandas-dev/pandas** merupakan salah satu proyek perangkat lunak open-source skala besar yang paling krusial di ekosistem Python. Sebagai pustaka standar analisis data, stabilitas dan efisiensi manajemen pengembangannya menjadi prioritas utama. Laporan kesehatan statistik ini bertujuan untuk melakukan audit kuantitatif terhadap manajemen issue dan pull request (PR) pada repositori tersebut guna mendeteksi bottleneck alur kerja.

Menggunakan data historis dari **5.000 issue tertutup** (issues_clean.csv), **5.000 PR tertutup** (prs_clean.csv), dan **data harian kedatangan issue selama 586 hari** (issues_per_day.csv), kami mengidentifikasi efisiensi penanganan serta tingkat keberhasilan kontribusi komunitas. Dari temuan statistik utama termasuk tingkat merge PR sebesar **70.42%** yang sangat tinggi, namun diiringi dengan rata-rata waktu penyelesaian issue sebesar **22.21 hari** yang secara signifikan melebihi target referensi 20 hari kami menyusun 3 rekomendasi mutakhir:

Rekomendasi Strategis Utama:

- **Penerapan Sistem Stale-Bot dan Eskalasi Otomatis:** Batasi penumpukan issue jangka panjang dengan mengaktifkan stale-bot otomatis pada hari ke-21 tanpa aktivitas guna mencegah issue melewati ambang batas kritis 30 hari. Berdasarkan simulasi Monte Carlo, probabilitas issue melewati batas 30 hari adalah sebesar **16.75%**.
- **Alokasi Ulang Kapasitas Reviewer untuk Triaging Issue:** Alihkan sebagian kapasitas kerja maintainer dari sekadar meninjau PR ke proses triaging issue di awal. Hambatan utama repositori saat ini terletak pada durasi penyelesaian issue yang secara statistik signifikan lebih lama dari target teoretis 20 hari.
- **Standardisasi Klasifikasi Kompleksitas (Difficulty Labeling):** Tekan variabilitas durasi penyelesaian issue yang sangat tinggi (standar deviasi sampel mencapai **58.89 hari**) dengan melabeli kompleksitas issue secara eksplisit ('Easy', 'Medium', 'Hard') pada saat triaging pertama kali.

2. Tinjauan Data (Data Overview)

Sumber Data dan Tautan Endpoint

Data diperoleh langsung melalui GitHub REST API dari repositori resmi **pandas-dev/pandas**. Berikut adalah tautan endpoint resmi yang digunakan dalam script penarikan data:

- **Endpoint Issues Tertutup:** https://api.github.com/repos/pandas-dev/pandas/issues?state=closed&per_page=100
- **Endpoint PR Tertutup:** https://api.github.com/repos/pandas-dev/pandas/pulls?state=closed&per_page=100

Cakupan Data dan Hasil Ekstraksi File

Nama File	Jumlah Data	Deskripsi
prs_clean.csv	5.000 PR	Closed Pull Requests untuk mengukur tingkat keberhasilan merge
issues_clean.csv	5.000 Issues	Closed Issues (difilter dari PR) untuk mengukur durasi penyelesaian
issues_per_day.csv	586 Hari	Akumulasi jumlah issue baru per hari untuk mengukur laju kedatangan

Rentang Waktu Operasional Dataset

- **Data Issues:** Tanggal pembuatan mulai dari 6 Oktober 2024 hingga 20 Mei 2026, dengan tanggal penutupan hingga 22 Mei 2026.
- **Data Pull Requests:** Tanggal pembuatan mulai dari 24 April 2024 hingga 20 Mei 2026, dengan tanggal penutupan hingga 22 Mei 2026.

Batasan Data (Data Limitations)

1. **Bias Seleksi (Selection Bias):** Analisis durasi hanya didasarkan pada issue dan PR yang telah ditutup (closed). Issue atau PR yang masih terbuka (open), yang kemungkinan memiliki hambatan berat, tidak tercakup dalam dataset.
2. **Presisi Variabel Durasi:** Waktu penyelesaian (close_time_days) dihitung berdasarkan selisih hari bulat (integer) antara tanggal ditutup dan tanggal dibuat.

3. Estimasi Parameter – Bagian 1

Formulasi Teoretis Maximum Likelihood Estimation (MLE)

Dalam audit ini, kami memformulasikan model MLE untuk dua variabel acak utama: status merge PR (variabel biner dari prs_clean.csv) dan jumlah issue baru per hari (variabel diskrit dari issues_per_day.csv).

1. Distribusi Bernoulli untuk Status Merge Pull Request

Misalkan status merge dari PR ke- i dinyatakan sebagai variabel acak $X_i \sim \text{Bernoulli}(p)$, di mana $X_i = 1$ jika PR sukses di-merge dan $X_i = 0$ jika ditutup tanpa di-merge. Probability Mass Function (PMF):

$$f(x_i; p) = p^{x_i} \cdot (1 - p)^{(1 - x_i)}$$

Fungsi Log-Likelihood $\ln L(p)$ untuk sampel berukuran n dengan $k = \sum x_i$ (total sukses):

$$\ln L(p) = k \cdot \ln(p) + (n - k) \cdot \ln(1 - p)$$

Derivatif pertama terhadap p disamakan dengan nol untuk mencari nilai maksimum:

$$d/dp [\ln L(p)] = k/p - (n-k)/(1-p) = 0 \Rightarrow \hat{p}_{MLE} = k/n$$

2. Distribusi Poisson untuk Jumlah Issue Masuk Harian

Misalkan jumlah issue baru harian pada hari ke- j adalah $Y_j \sim \text{Poisson}(\lambda)$, di mana λ adalah rata-rata kedatangan issue per hari. PMF dari Y_j :

$$f(y_j; \lambda) = [e^{(-\lambda)} \cdot \lambda^{y_j}] / y_j!$$

Fungsi Log-Likelihood $\ln L(\lambda)$ dengan mengabaikan suku tanpa parameter λ :

$$\ln L(\lambda) = -m \cdot \lambda + (\sum Y_j) \cdot \ln(\lambda)$$

Derivatif pertama terhadap λ disamakan dengan nol:

$$d/d\lambda [\ln L(\lambda)] = -m + (\sum Y_j)/\lambda = 0 \Rightarrow \hat{\lambda}_{MLE} = (\sum Y_j) / m = \bar{Y}$$

3. Estimasi Parameter – Bagian 2

Nilai Estimasi Titik Parameter Berdasarkan Data Riil

$$\hat{p}_{MLE} = 3521 / 5000 = 0.704200 \text{ (70.42\%)}$$

$$\hat{\lambda}_{MLE} = 5000 / 586 = 8.532423 \text{ issue/hari}$$

Parameter	Nilai Estimasi MLE
Probabilitas Merge PR ($\hat{p}_{MLE}$)	$3521 / 5000 = 0.704200 \text{ (70.42\%)}$
Rata-rata Issue Harian ($\hat{\lambda}_{MLE}$)	$5000 / 586 = 8.532423 \text{ issue/hari}$

Pembaruan Bayesian (Bayesian Update) untuk Status Merge PR


Menggunakan prior Konjugat **Beta($\alpha=12, \beta=8$)** yang berasumsi tingkat merge historis di kisaran 60%. Dengan masuknya data sampel baru ($k=3521, n-k=1479$), parameter posterior diperbarui:

$$\alpha_{post} = 12 + 3521 = 3533 \quad | \quad \beta_{post} = 8 + 1479 = 1487$$

Distribusi posterior menjadi **Beta(3533, 1487)** dengan properti:

Mean Posterior	Mode Posterior	95% Credible Interval
$3533 / 5020 = 0.703785$ (70.38%)	$3532 / 5018 = 0.703866$ (70.39%)	[0.691079, 0.716336]

MLE Bernoulli - MLE Poisson - Beta Posterior



Gambar 3.1: Kurva Bayesian Update (Kiri) dan Kesesuaian Distribusi Poisson (Kanan)

4. Interval Kepercayaan – Bagian 1

1. Interval Kepercayaan untuk Probabilitas Merge PR (p)

Dengan ukuran sampel besar ($n = 5.000$) dari `prs_clean.csv`, pendekatan normal (Wald Interval) dijalankan menggunakan nilai kritis $z(0.025) = 1.959964$:

$$SE(\hat{p}) = \sqrt{[\hat{p} \cdot (1-\hat{p}) / n]} = \sqrt{[0.7042 \cdot 0.2958 / 5000]} = 0.0064545$$

$$\text{Margin of Error (ME)} = 1.959964 \times 0.0064545 = 0.012651$$

$$CI_{95\%}(p) = 0.704200 \pm 0.012651 \Rightarrow [0.691549, 0.716851]$$

2. Interval Kepercayaan untuk Laju Kedatangan Issue Harian (λ)

Menggunakan sampel $m = 586$ hari dari `issues_per_day.csv`, kesalahan baku dihitung dengan $SE(\lambda) = \sqrt{(\lambda/m)}$:

$$SE(\lambda) = \sqrt{[8.532423 / 586]} = 0.120667$$

$$\text{Margin of Error (ME)} = 1.959964 \times 0.120667 = 0.236503$$

$$CI_{95\%}(\lambda) = 8.532423 \pm 0.236503 \Rightarrow [8.295921, 8.768926]$$

Parameter	Batas Bawah	Batas Atas
Probabilitas Merge PR (p)	0.691549	0.716851
Laju Issue Harian (λ)	8.295921	8.768926

4. Interval Kepercayaan – Bagian 2

Interpretasi Frekuentis Tepat dalam Bentuk Prosa


Interpretasi frekuentis yang tepat untuk interval kepercayaan 95% dari tingkat merge PR [0.6915, 0.7169] adalah: *Jika kita melakukan pengambilan sampel secara berulang kali sebesar 5.000 PR secara independen dari populasi jangka panjang repositori Pandas dan menghitung interval kepercayaan 95% untuk setiap sampel tersebut, maka 95% dari interval-interval yang terbentuk akan mengandung nilai parameter probabilitas merge PR yang sebenarnya.* Kita dilarang menyatakan ada probabilitas 95% parameter berada di dalam cakupan angka tersebut pada sampel tunggal, karena parameter bernilai konstan tetap.

Komparasi dengan Bayesian Credible Interval

Interval Kredibel 95% Bayesian [0.6911, 0.7163] mengizinkan pernyataan probabilitas subjektif: terdapat probabilitas 95% nilai parameter p berada di dalam rentang tersebut berdasarkan data sampel dan prior. Karena ukuran sampel sangat besar ($n=5.000$), efek prior teredam oleh data likelihood, menghasilkan batas interval frekuentis dan Bayesian yang berkonvergensi (hampir identik).

Metode	Batas Bawah	Batas Atas	Selisih
Wald Interval (Frekuentis)	0.691549	0.716851	0.025302
Beta Posterior (Bayesian)	0.691079	0.716336	0.025257

Kesimpulan Komparasi: Kedua metode menghasilkan interval yang nyaris identik karena $n=5.000$ menekan pengaruh prior secara efektif. Hasil ini mengkonfirmasi konsistensi analisis dari perspektif frekuentis maupun Bayesian.



Gambar 4.1: Perbandingan Interval Kepercayaan 95% (Frekuentis vs Bayesian)

5. Uji Hipotesis – Bagian 1

Prosedur Formal 6 Langkah

Uji hipotesis dirancang untuk membuktikan secara inferensial apakah performa durasi kerja repositori memenuhi target teoretis $\mu_0 = 20$ hari menggunakan variabel `close_time_days` pada file `issues_clean.csv`.

Langkah 1: Formulasi Hipotesis

$H_0 : \mu = 20$ (rata-rata populasi waktu penyelesaian issue = 20 hari)

$H_a : \mu \neq 20$ (rata-rata populasi waktu penyelesaian issue $\neq$ 20 hari)

Langkah 2: Tingkat Signifikansi

$$\alpha = 0.05$$

Justifikasi Asumsi Berdasarkan CLT

Data mentah `close_time_days` memiliki ketimpangan (skewness) kanan yang ekstrem banyak issue selesai di bawah 5 hari, namun beberapa issue selesai dalam ratusan hari. Meskipun tidak berdistribusi normal, pengujian menggunakan **One-Sample Z-Test** tetap valid karena ukuran sampel yang sangat besar ($n = 5.000$). Berdasarkan CLT, distribusi sampling dari rata-rata sampel ($\bar{X}$) dijamin mendekati distribusi normal secara asimtotik seiring besarnya nilai n .

5. Uji Hipotesis – Bagian 2

Langkah 3: Pemilihan Statistik Uji

Statistik uji yang digunakan untuk ukuran sampel besar ($n \geq 30$) adalah statistik Z:

$$Z = (\bar{X} - \mu_0) / SE \quad \text{di mana } SE = s / \sqrt{n}$$

Langkah 4: Kalkulasi Numerik Eksplisit

Statistik deskriptif yang dihitung langsung dari dataset riil `issues_clean.csv`:

Statistik Deskriptif	Nilai
Ukuran Sampel (n)	5.000 issue
Rata-rata Sampel ($\bar{X}$)	22.208200 hari
Standar Deviasi Sampel (s)	58.891270 hari
Standard Error (SE)	0.832848 hari
Statistik Z_hitung	2.651383
P-value	0.008016

Kalkulasi langkah demi langkah:

$$SE = s / \sqrt{n} = 58.891270 / \sqrt{5000} = 0.832848 \text{ hari}$$

$$Z_{hitung} = (\bar{X} - \mu_0) / SE = (22.208200 - 20) / 0.832848 = 2.651383$$

Nilai **Z_hitung = 2.651383** mengindikasikan bahwa rata-rata sampel berada sejauh 2.65 kali kesalahan baku di atas nilai klaim hipotesis nol.

5. Uji Hipotesis – Bagian 3

Langkah 5: Daerah Kritis dan Perhitungan P-value

Untuk uji dua arah dengan $\alpha = 0.05$, batas daerah penolakan adalah $Z > 1.96$ atau $Z < -1.96$. Karena $Z_{\text{hitung}} = 2.651383 > 1.96$, titik data masuk ke dalam wilayah penolakan sisi kanan.

$$P\text{-value} = 2 \cdot (1 - \Phi(|Z_{\text{hitung}}|)) = 2 \cdot (1 - \Phi(2.651383))$$


$$\Phi(2.651383) = 0.995992$$

$$P\text{-value} = 2 \cdot (1 - 0.995992) = 0.008016$$

Langkah 6: Keputusan dan Kesimpulan Statistik

Kriteria Keputusan	Hasil
P-value vs α	$0.008016 < 0.05$
Z_{hitung} vs Z_{kritis}	$2.651383 > 1.96$
Keputusan	TOLAK H_0

Kesimpulan: Terdapat bukti statistik yang kuat untuk menyatakan bahwa rata-rata waktu penyelesaian issue pada repositori Pandas tidak sama dengan 20 hari. Secara faktual, rata-rata durasi penyelesaian (22.21 hari) secara signifikan lebih lambat dari target operasional.



Gambar 5.1: Sebaran Empiris Eksponensial dan Outlier Waktu Penyelesaian Issue Pandas

6. Analisis Komputasional – Bagian 1

Batasan Rumus Matematika Tertutup (Analitis)

Pendekatan analitis bergantung pada pemenuhan asumsi sebaran parameter yang kaku. Pada file `issues_clean.csv`, variabel `close_time_days` memiliki karakteristik sebaran ekor panjang (heavy-tailed) dengan nilai pencilan ekstrem. Standar deviasi sampel ($s = 58.891270$) bernilai hampir 3 kali lipat dibanding nilai rata-ratanya sendiri. Memaksakan model distribusi parametrik standar akan memicu bias kalkulasi yang besar pada area ekor.

Justifikasi Ilmiah Pemilihan Teknik Simulasi Monte Carlo

Untuk mengestimasi probabilitas issue acak diselesaikan melebihi ambang batas kritis (>30 hari), kami menerapkan **Simulasi Monte Carlo berbasis empirical resampling (bootstrapping)**:

3. **Keunggulan Monte Carlo:** Teknik ini mengekstrak sampel acak berulang secara langsung dari data empiris tanpa memedulikan bentuk teoretis asalnya. Sifat pencilan ekstrem dan skewness riil tetap terjaga.
4. **Ketidaktepatan Bloom Filter:** Bloom Filter merupakan struktur data probabilistik untuk menguji keanggotaan elemen (set membership), bukan alat kalkulasi fungsi sebaran peluang kontinu.
5. **MCMC Tidak Diperlukan:** Markov Chain Monte Carlo dibutuhkan untuk integrasi ruang dimensi tinggi pada posterior non-konjugat. Kasus satu dimensi ini dapat diselesaikan secara langsung lewat sampling Monte Carlo biasa tanpa risiko burn-in dan autokorelasi rantai.

6. Analisis Komputasional – Bagian 2

Implementasi Algoritma Komputasi


Simulasi dieksekusi melalui **10.000 iterasi** menggunakan resampling berukuran sampel senilai 5.000 baris per iterasi dengan pengembalian (`replace=True`). Target komputasi adalah menghitung rasio frekuensi kemunculan nilai elemen yang memenuhi syarat `close_time_days > 30`.

Hasil Komputasi Resampling

Metrik	Nilai
Proporsi Aktual Sampel Awal	0.167600
Estimasi Probabilitas Monte Carlo	0.167548 (16.75%)
Standar Error Peluang Simulasi	0.005273
95% CI Simulasi (Persentil)	[0.157200, 0.178000]

Interpretasi Hasil Simulasi

Simulasi memberikan kepastian dengan presisi tinggi bahwa probabilitas sebuah issue acak memakan waktu penyelesaian di atas 30 hari adalah sebesar **16.75%**. Dengan rentang kepercayaan yang sempit (15.72% hingga 17.80%), dapat disimpulkan secara mantap bahwa **1 dari 6 issue** yang masuk ke repositori Pandas dipastikan masuk ke kategori backlog kronis jangka panjang.



Gambar 6.1: Distribusi Waktu Penyelesaian dan Hasil Simulasi Monte Carlo

7. Rekomendasi Bagi Maintainer

Tindakan Strategis Berbasis Bukti Statistik (Data-Driven)

Rekomendasi 1: Aktivasi Kebijakan Stale-Bot Otomatis di Hari ke-21

Bukti Statistik	Simulasi Monte Carlo membuktikan 16.75% issue terjebak dalam penanganan berskala >30 hari. 95% CI: [0.157200, 0.178000].
Tindakan	Konfigurasikan bot otomatis untuk menyematkan label 'stale' jika sebuah issue pasif selama 21 hari berturut-turut. Jika interaksi tetap nihil dalam 7 hari pasca-notifikasi, tutup issue secara otomatis.

Rekomendasi 2: Alokasi Ulang Fokus Core Developer – Prioritaskan Triaging Issue

Bukti Statistik	Merge rate sudah efisien di 70.42% (95% CI: [0.6915, 0.7169]), namun uji hipotesis membuktikan rata-rata waktu penanganan issue (22.21 hari) gagal memenuhi target 20 hari secara signifikan ($P = 0.008016$).
Tindakan	Pindahkan sebagian jam kerja peninjauan PR sekunder dari maintainer untuk memperkuat proses triaging issue di hulu, guna memperjelas deskripsi bug sebelum dikerjakan oleh kontributor luar.

Rekomendasi 3: Standardisasi Label Skala Kompleksitas Berbasis Variansi

Bukti Statistik	Standar deviasi durasi penanganan issue sangat besar ($s = 58.891270$ hari), memvalidasi adanya ketimpangan kompleksitas penanganan yang tidak terukur.
Tindakan	Wajibkan pelabelan tingkat kesulitan standar ('Easy/Good-First-Issue', 'Medium', 'Hard') pada hari pertama issue dibuat guna memandu kontributor mengambil penugasan yang sesuai kapasitas kompetensi mereka.